

清華大學
Tsinghua University

(7) DeepCAVE-X: 基于强化学习的自适应 HPO 配置

王羿珧 2026211232

2026.09.13

> 选题依据

选题背景、研究现状、开发想法

> 选题背景

- AutoML 旨在自动化机器学习流程，其中 Hyperparameter Optimization (HPO) 负责 ***自动搜索*** 模型超参数 [1]

- **自动搜索？一个复杂的实验过程**

HPO：配置 (范围、方法、...) -> 搜索超参数 -> 反馈 -> 再配置。[2]

- **所谓的 超参自动搜索 有前提：配置**

配置 决定了 HPO 的搜索

Search Space 过小：遗漏最优区域

Search Space 过大：搜索效率下降

自动化超参搜索依赖配置，配置很重要

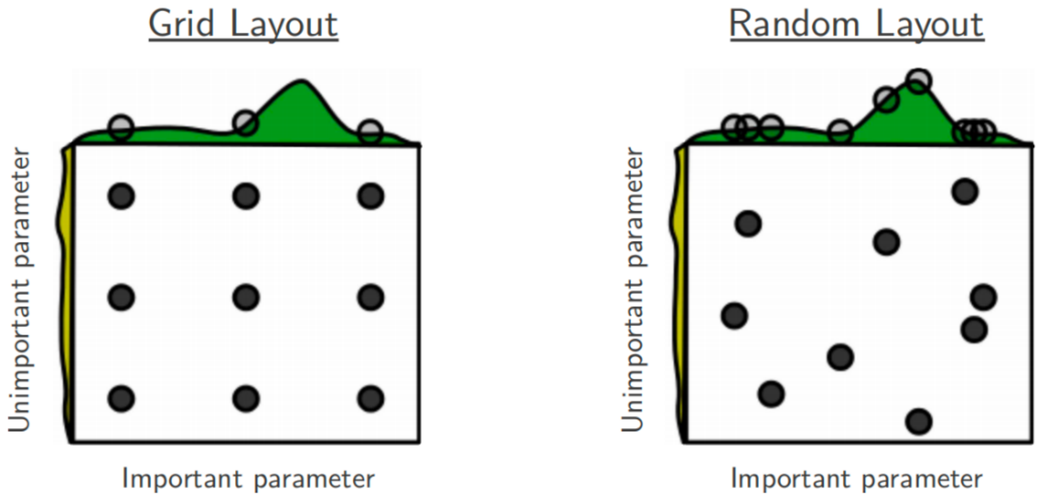


图1 两种基本的 HPO 算法 [1]

> 研究现状 现有研究和框架怎样配置?

人主导的 HPO 配置

人为配置 -> 传统 HPO -> 超参 -> 迭代配置

CAVE (2021) [3]、DeepCAVE (2025) [4]

- 优: 增强透明性、提高用户对算法的信任 [5]
- 缺: 高度依赖人工经验





> 依赖人工

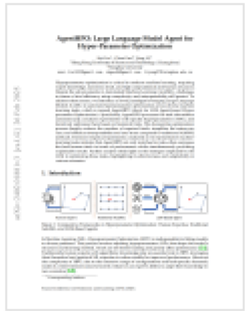
Agent 驱动的 HPO 配置

LLM Agent 配置 -> LLM HPO -> 超参

AgentHPO (2025) [6]、AutoML-Agent (2025) [7]

- 优: 降低人工配置成本
- 缺: 并非全自动配置; LLM HPO 不如传统 HPO [8]





> 搜索过程不透明、搜索效果不佳

> 开发动机与想法

结合两种配置方式的优势：Agentic Setup + Classical HPO

自动化配置 -> 传统 HPO -> 超参轨迹分析 -> Agent 迭代配置 -> ...

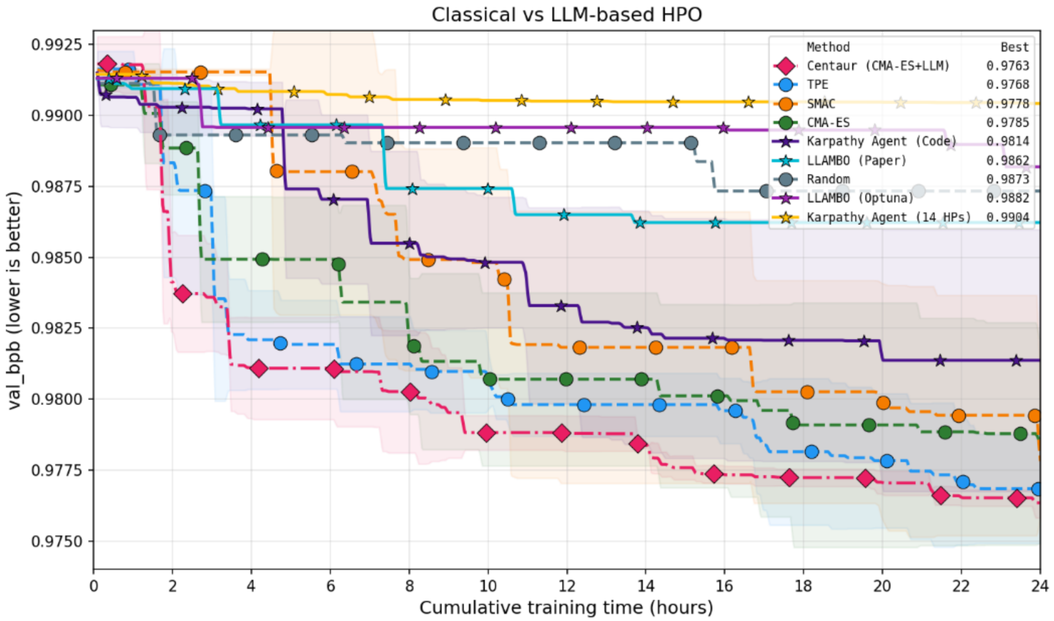


图2 LLM-based HPO vs 传统 HPO [8]

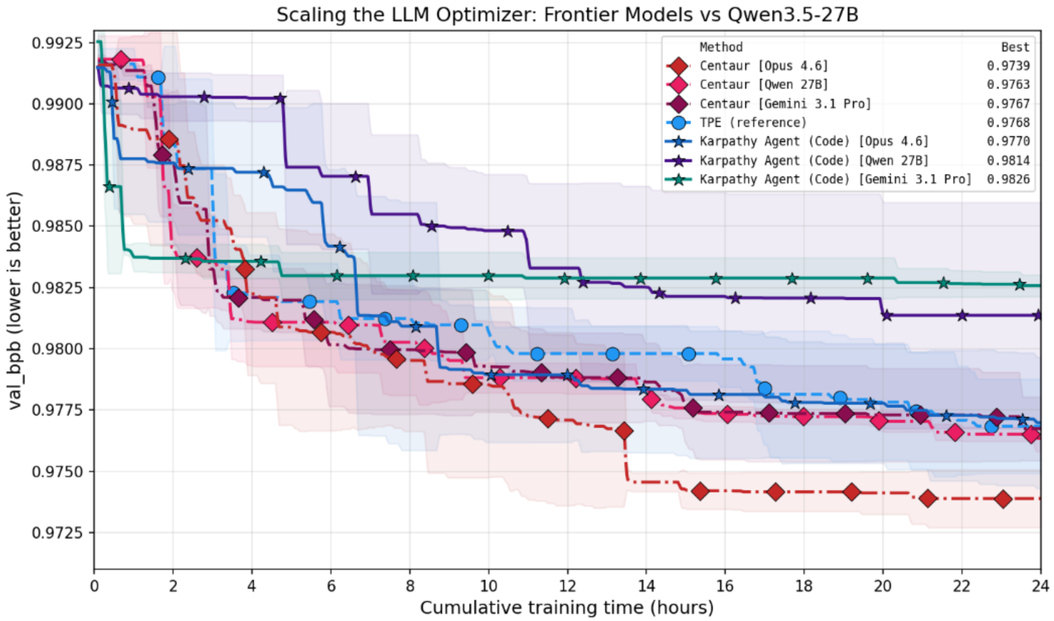


图3 Scaled-LLM 依然无法击败传统 HPO [8]

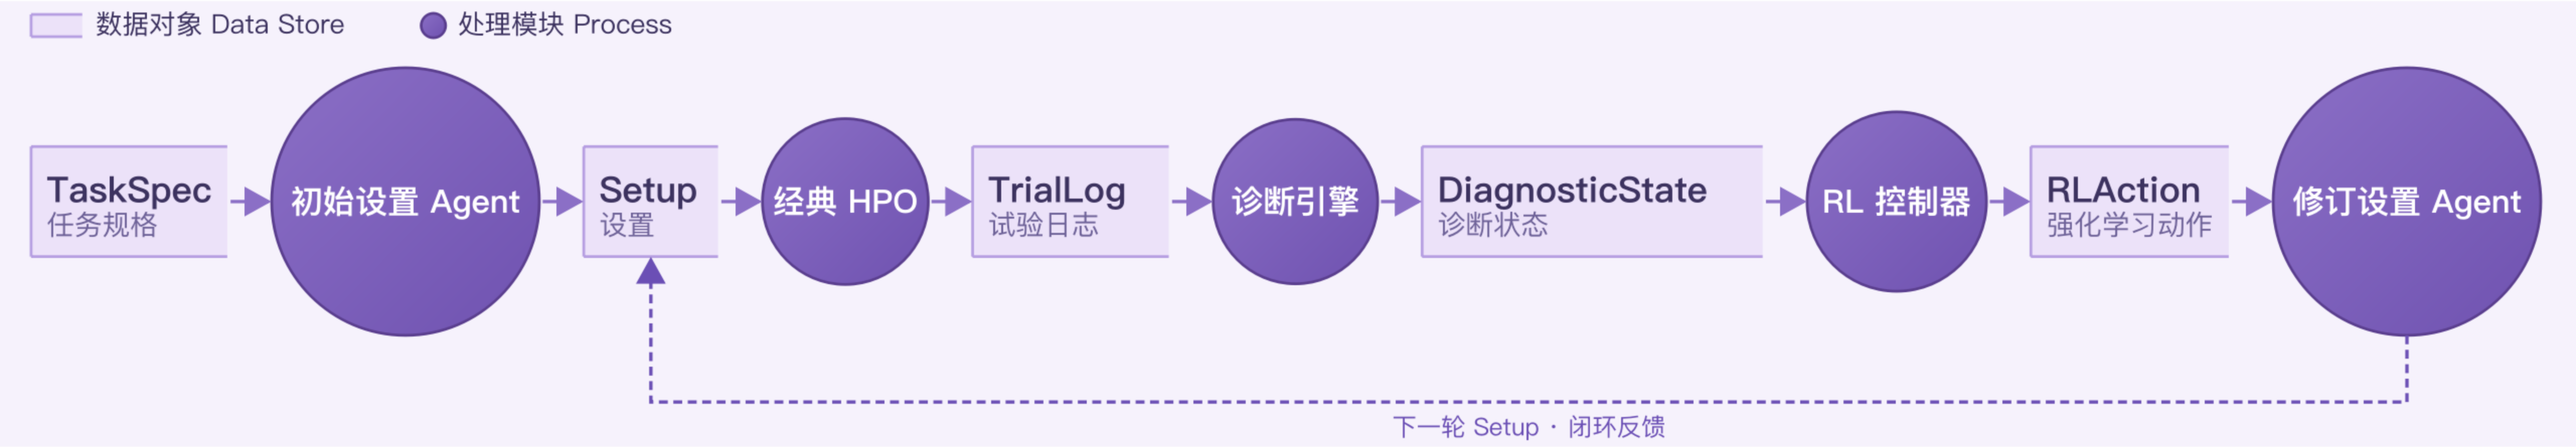
> 开发方案

拟解决的问题、开发方案、技术栈与技术路线

> 拟解决的问题与开发方案

自动化配置 -> 传统 HPO -> 超参轨迹分析 -> Agent 迭代配置 -> ...

1. 如何实现超参搜索前的**自动化配置**?
2. 如何根据超参迭代轨迹进行**诊断分析**，使得分析内容能够帮助**迭代配置**?

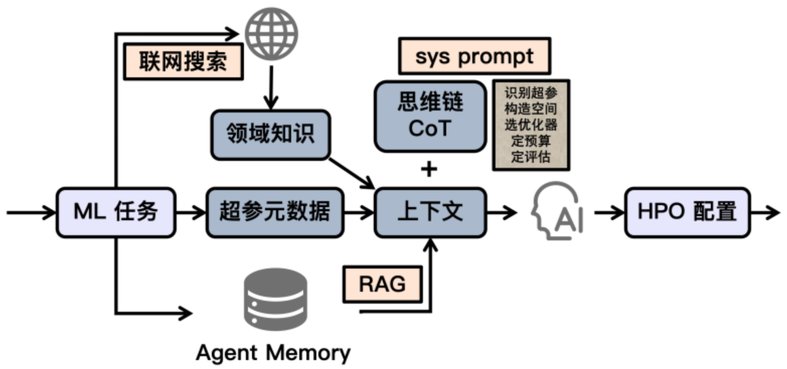


1. 【初始设置Agent】任务、超参元数据、Agent Memory → 搜索空间、HPO 优化器、预算
   【修订设置Agent】诊断证据、RL Action、Agent Memory → 下一轮配置
2. 【诊断引擎】定义好的规则。Trial 日志 → 结构化诊断状态 {超参重要性、边界聚集、优良区域、...}
3. 【RL 控制】Q-Learning。State → Action 映射，以目标改进的收益减预算代价作为奖励驱动

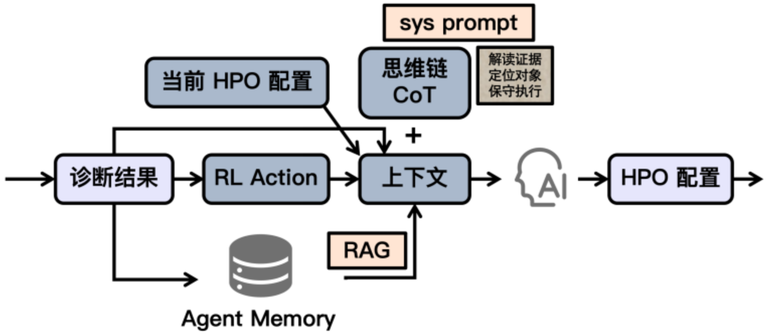
> 技术栈与技术路线

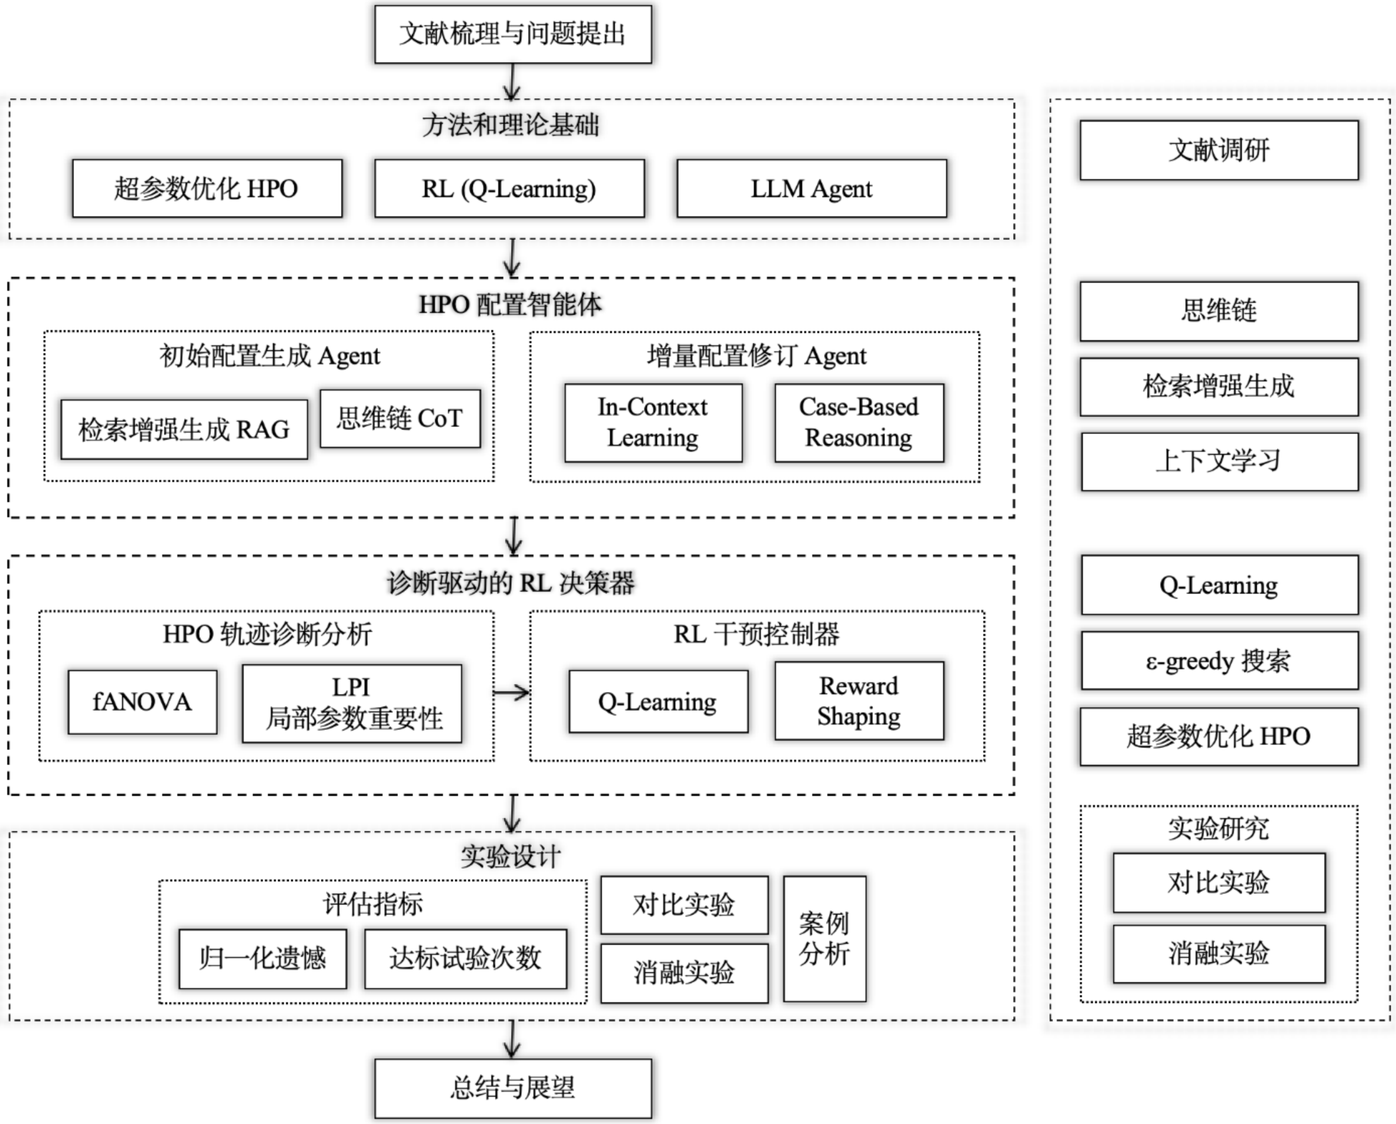
1. HPO 配置 Agent

1.1 初始配置生成 Agent



1.2 增量配置修订 Agent

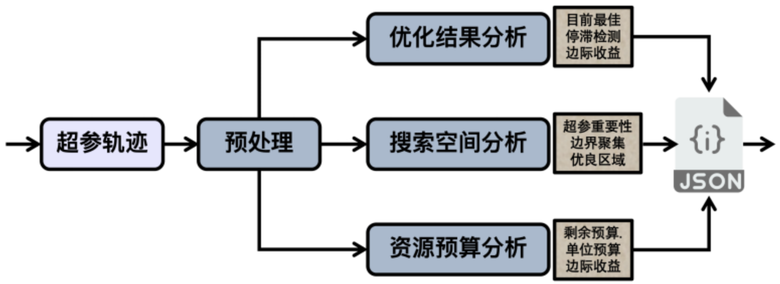




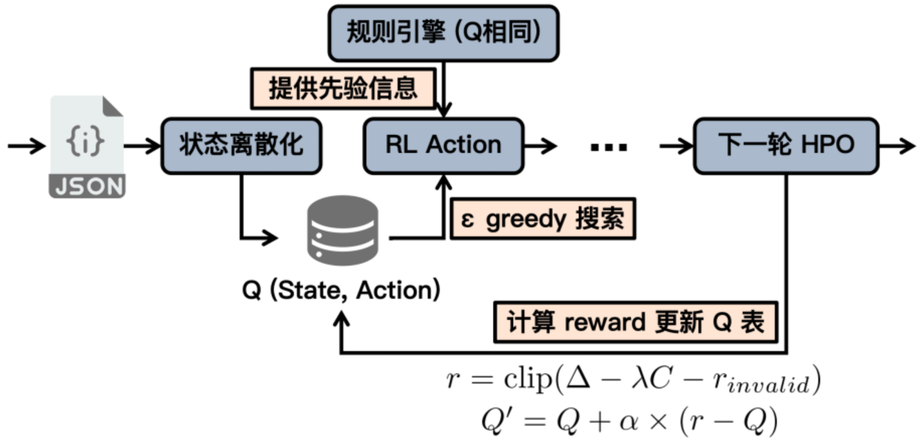
> 技术栈与技术路线

2. 诊断驱动的 RL

2.1 HPO 轨迹诊断分析

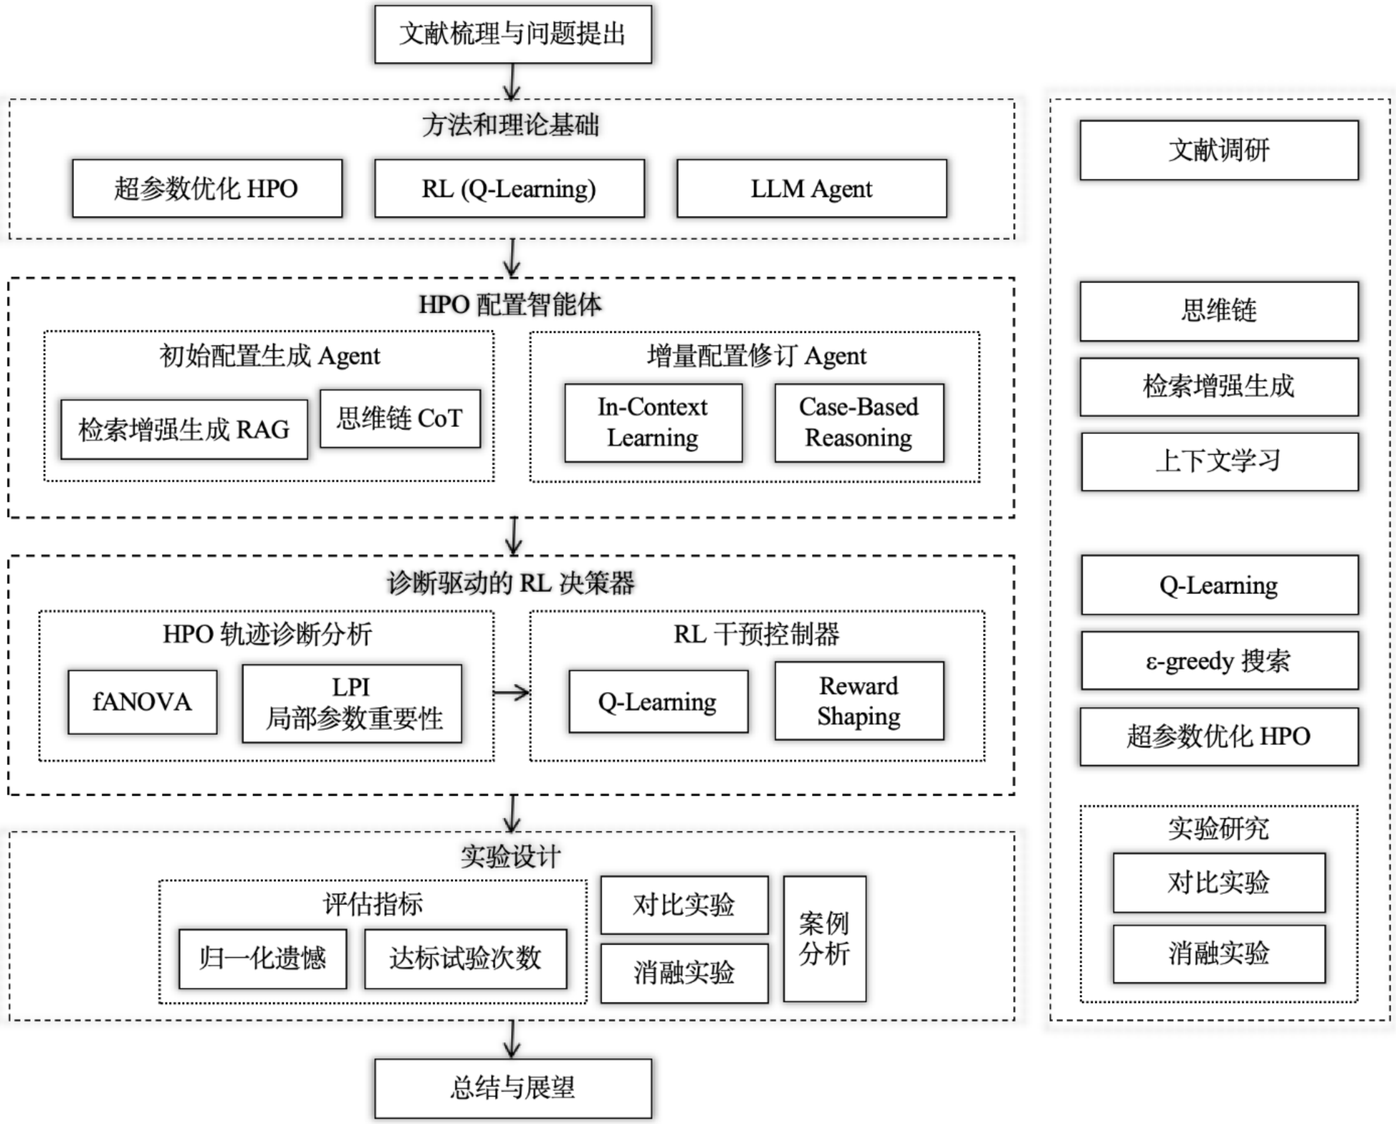


2.2 RL 干预控制器



$$r = \text{clip}(\Delta - \lambda C - r_{invalid})$$

$$Q' = Q + \alpha \times (r - Q)$$



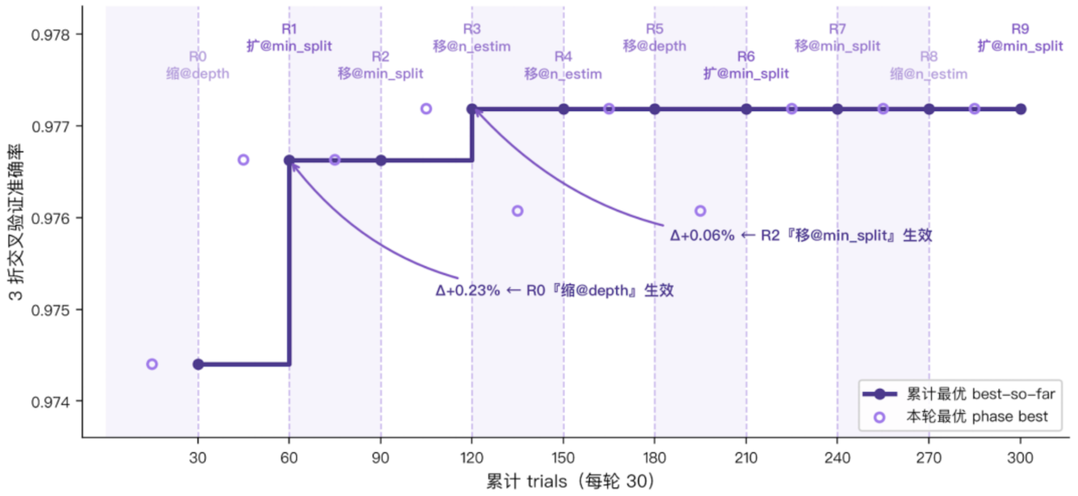
> 预期计划

预期成果、可行性分析、任务计划

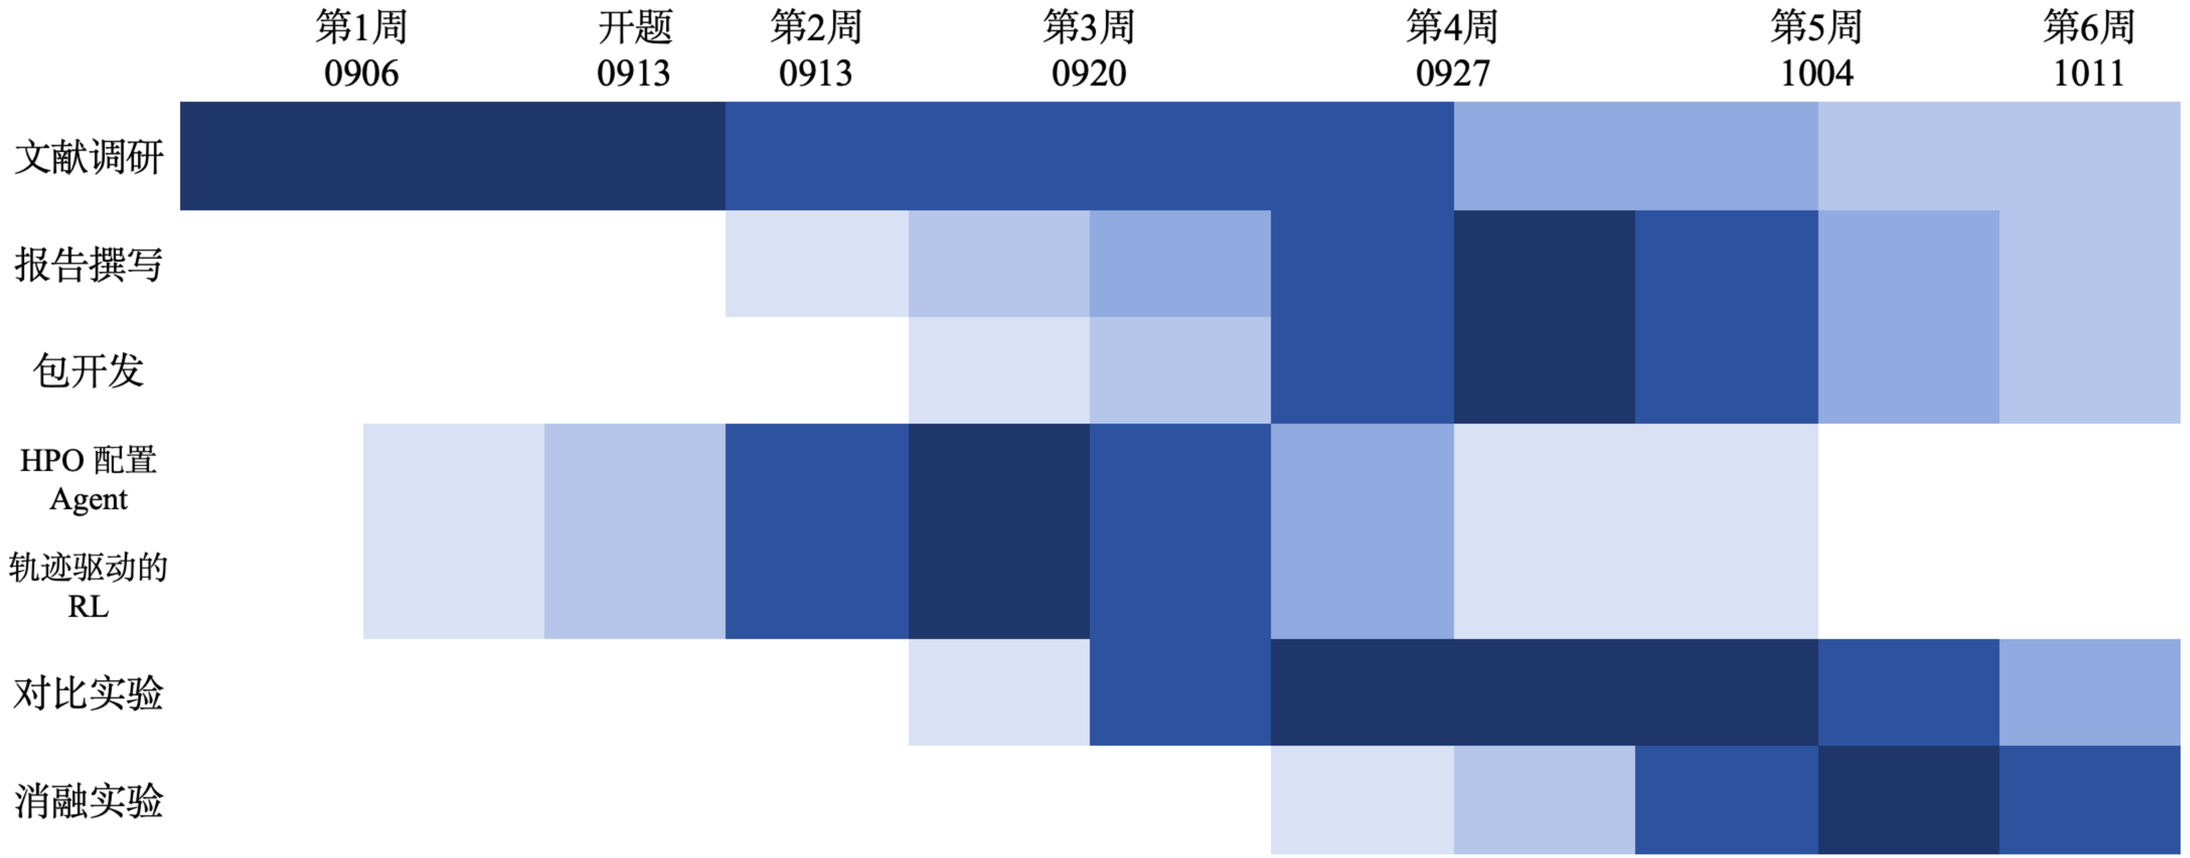
> 预期成果与可行性分析

- 开源工具包 HPO-adapt
  - **基于 RL 的诊断驱动 HPO 配置自适应**
    - 无需具备超参配置的领域知识
    - 一次命令完成超参数优化
  - **独立的轨迹诊断引擎 DeepCAVE-X**
    - 提供透明性
- 论文
  - Observe–Decide–Execute 三层架构
    - 规则 - RL 控制 - Agent
  - **核心贡献**
    - 确定适配器位置
    - 确定适配器结构 - 瓶颈结构
    - 性能指标突破 - 与静态配置对比

- 初步模块开发
  - 双后端 Setup Agent（heuristic/LLM）、7 种干预动作的修订 Agent、Optuna HPO 执行器
  - 诊断引擎（fANOVA、LPI、最优值、停滞判定、...）、表格 Q-Learning 控制器
  - Schema 校验、基于 SQLite 的 Agent Memory
- Sklearn 手写数字 + 随机森林



> 任务计划


第1周
0906
开题
0913
第2周
0913
第3周
0920
第4周
0927
第5周
1004
第6周
1011
文献调研
报告撰写
包开发
HPO 配置 Agent
轨迹驱动的 RL
对比实验
消融实验

> 总结

总结、参考文献

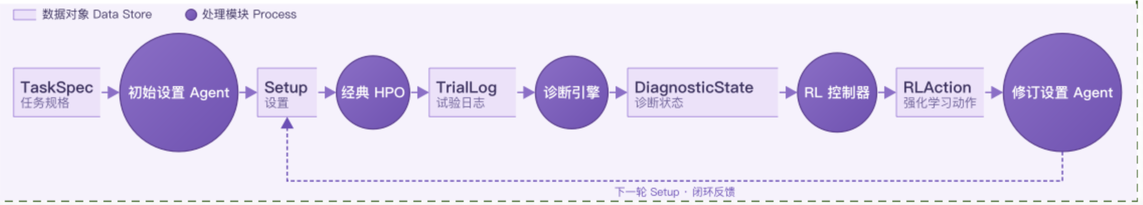
> 总结

研究动机

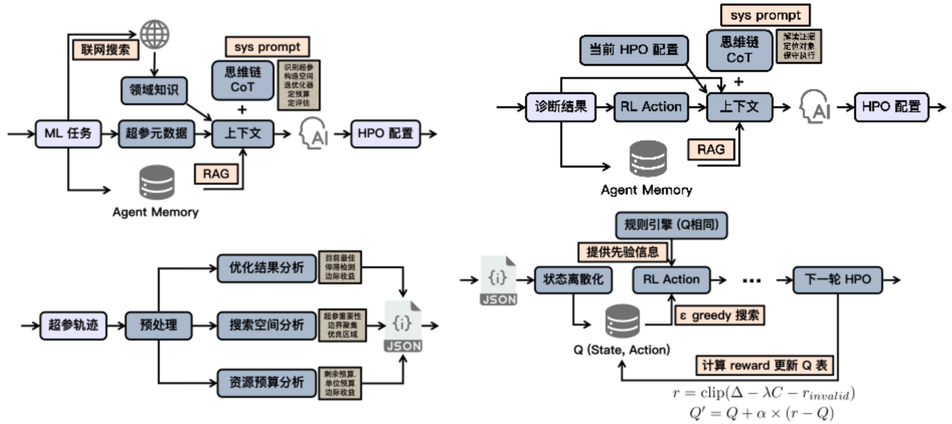
- HPO 负责自动搜索模型超参数配置
- 自动化超参搜索依赖配置，配置很重要
- Agentic Setup + Classical HPO

研究方案

- HPO 配置 Agent
  - 初始配置生成 Agent、增量配置修订 Agent
- 诊断驱动的 RL
  - HPO 轨迹诊断分析、RL 干预控制器



模块设计

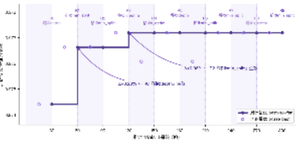


初步模块开发

- 模块开发

  双后端 Setup Agent（heuristic/LLM）、7 种干预动作的修订 Agent、Optuna HPO 执行器
  诊断引擎（fANOVA、LPI、最优值、停滞判定、...）、表格 Q-Learning 控制器
  Schema 校验、基于 SQLite 的 Agent Memory

- Sklearn 手写数字 + 随机森林



> PPT 中的参考文献

1. Bergstra J, Bengio Y. Random search for hyper-parameter optimization[J]. Journal of Machine Learning Research, 2012.
2. Tornede A, Deng D, Eimer T, et al. AutoML in the age of large language models: Current challenges, future opportunities and risks[J]. Transactions on Machine Learning Research, 2024.
3. He X, Zhao K, Chu X. AutoML: A survey of the state-of-the-art[J]. Knowledge-Based Systems, 2021, 212.
4. Segel S, Graf H, Bergman E, et al. DeepCAVE: A visualization and analysis tool for automated machine learning[J]. Journal of Machine Learning Research, 2025.
5. Drozdal J, Weisz J, Wang D, et al. Trust in AutoML: Exploring information needs for establishing trust in automated machine learning systems[C]. Proceedings of the 25th International Conference on Intelligent User Interfaces, 2020.
6. Liu S, Gao C, Li Y. AgentHPO: Large language model agent for hyper-parameter optimization[C]. Conference on Parsimony and Learning, 2025.
7. Trirat P, Jeong W, Hwang S J. AutoML-Agent: A multi-agent LLM framework for full-pipeline AutoML[C]. Proceedings of the 42nd International Conference on Machine Learning, 2025.
8. Ferreira F, Wobbe L, Krishnakumar A, et al. Can LLMs beat classical hyperparameter optimization algorithms? A study on autoresearch[EB/OL]. arXiv, 2026.

清華大學
Tsinghua University

请老师批评指正

王羿珧 2026211232

2026.09.13